Primera entrega Proyecto ETL

Juan Jose Alban- 2235677

Asignatura:

ETL (Extracción, Transformación y carga)

Docente:

Daniel Felipe Romero

Universidad Autónoma de Occidente

Informe Técnico: Implementación ETL – Violencia Intrafamiliar en Colombia

Curso: ETL (G51)

Estudiante: Juan José Albán

Repositorio: https://github.com/alban0918/ETL-Violencia-Intrafamiliar

1. Contexto y requerimientos del proyecto

El objetivo principal de este proyecto es diseñar e implementar un proceso completo de ETL (Extracción, Transformación y Carga) utilizando un conjunto de datos público relacionado con la violencia intrafamiliar en Colombia.

Los requerimientos del proyecto incluyen:

- Seleccionar un conjunto de datos alineado con un Objetivo de Desarrollo Sostenible (ODS).

- Migrar los datos a una base de datos relacional.

- Realizar un Análisis Exploratorio de Datos (EDA).

- Construir visualizaciones significativas conectadas directamente a la base de datos.

2. Alineación con los Objetivos de Desarrollo Sostenible (ODS)

Este proyecto se alinea principalmente con:

- ODS 5: Igualdad de Género.

- ODS 16: Paz, Justicia e Instituciones Sólidas.

La violencia intrafamiliar es un problema social que afecta directamente la seguridad, la equidad y el bienestar de la población. El análisis de estos datos permite identificar patrones y apoyar la toma de decisiones basadas en evidencia.

3. Selección y evaluación de la fuente de datos

El conjunto de datos seleccionado es "Reporte Delito Violencia Intrafamiliar – Policía Nacional", obtenido del portal datos.gov.co.

Criterios de selección:

- Fuente oficial y confiable.

- Más de 660,000 registros.

- Variables relevantes como: departamento, municipio, género, grupo etario y fecha.

- Estructura clara y adecuada para análisis.

4. Arquitectura y pila tecnológica

La arquitectura ETL implementada consta de las siguientes fases:

Extracción:

- Descarga del archivo CSV desde datos.gov.co.

Transformación:

- Limpieza de datos.

- Manejo de valores nulos.

- Conversión de fechas.

- Normalización de categorías.

- Creación de columnas temporales (año, mes, día, día de la semana).

Carga:

- Prueba inicial usando SQLite para validar el proceso ETL.

- Migración final a una base de datos PostgreSQL en Supabase.

Visualización:

- Power BI conectado directamente a la base de datos.

5. Modelo de datos

Se implementó un modelo tipo estrella (Star Schema), compuesto por:

- Tabla de hechos: registros de violencia intrafamiliar.
- Tablas de dimensiones: tiempo, género, grupo etario y ubicación geográfica.

Este modelo facilita la consulta y el análisis desde herramientas de visualización.

6. Resumen del Análisis Exploratorio de Datos (EDA)

El proceso de EDA permitió:

- Identificar valores faltantes y corregirlos.
- Analizar tendencias anuales.
- Comparar casos por género.
- Evaluar distribución por grupo etario.
- Identificar departamentos con mayor número de casos.

Se observaron patrones importantes relacionados con el crecimiento de los casos en determinados años y una mayor afectación en población femenina y adulta.

7. Visualizaciones

Se desarrolló un dashboard en Power BI conectado directamente a la base de datos.

Violencia Intrafamiliar en Colombia

Juan Jose Alban

Registro de casos · 2010 – 2025 · Fuente: DIJIN - Policía Nacional

Seleccionar todo | FEMENINO | MASCULINO

Total Casos
1,39 mill.
Registros de 2010-2025

Género Femenino
74.8%
~1.03M víctimas

Adultos
91.5%
Grupo etario principal

Top Depto.
CUNDINAMARCA
Mayor número de casos

Distribución por Género

Víctimas registradas

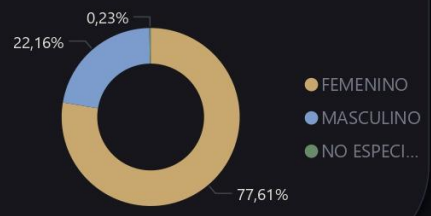

Distribución por Grupo Etario

Víctimas registradas

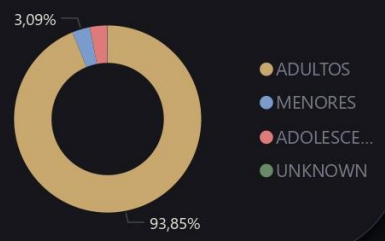

Evolución Anual de la Violencia Intrafamiliar

Número de casos registrados por año · 2010–2025

Casos por Día de la Semana

Distribución semanal de reportes

Las visualizaciones permiten responder claramente a los objetivos del proyecto.

8. Propuesta de automatización del proceso ETL con n8n (fase futura)

Como trabajo futuro, se propone la implementación de una automatización completa del proceso ETL mediante la herramienta n8n, con el fin de transformar este proyecto en un sistema de actualización continua de datos.

Actualmente, el proceso ETL se ejecuta de manera manual a través de Google Colab, donde se descargan los datos, se limpian, se transforman y se cargan en la base de datos PostgreSQL (Supabase). Sin embargo, este flujo puede ser automatizado para mejorar la eficiencia, reducir errores humanos y garantizar que el dashboard se mantenga actualizado con información reciente.

La implementación con n8n permitiría construir un flujo automático con las siguientes etapas:

Descarga automática del dataset

n8n se conectaría periódicamente al portal de datos abiertos (datos.gov.co) para descargar la versión más reciente del archivo CSV del reporte de violencia intrafamiliar.

Ejecución del proceso de transformación

Una vez descargados los datos, n8n ejecutaría un script de transformación previamente definido (basado en el proceso realizado en Python), donde se realizaría:

Limpieza de datos.

Normalización de categorías.

Conversión de fechas.

Creación de columnas temporales (año, mes, día, día de la semana).

Carga automática en la base de datos

Los datos transformados se insertarían automáticamente en la base de datos PostgreSQL alojada en Supabase, asegurando la integridad y consistencia de la información.

Actualización del dashboard

Al estar Power BI conectado directamente a la base de datos, cada actualización de los datos permitiría que el dashboard refleje automáticamente la información más reciente, sin intervención manual.

Este enfoque convertiría el proyecto en un sistema ETL automatizado y escalable, alineado con prácticas reales de ingeniería de datos. Además, permitiría programar ejecuciones periódicas (por ejemplo, semanal o mensual), garantizando la disponibilidad de datos actualizados para análisis y toma de decisiones.

La incorporación de n8n como herramienta de orquestación representa una evolución natural del proyecto hacia una arquitectura más robusta, demostrando cómo un proceso académico puede proyectarse hacia una solución de tipo productivo.

9. Conclusiones

El proyecto demuestra la implementación completa de un proceso ETL desde la extracción de datos hasta la visualización final.

El análisis realizado contribuye a la comprensión del fenómeno de la violencia intrafamiliar en Colombia y se alinea con los Objetivos de Desarrollo Sostenible, aportando una herramienta útil para análisis social y toma de decisiones.